

# Proyecto ICM3480: Detección de fallas y caracterización de zona de peligro

Vicente Bañados, Fernando Bittelman, Martin Salinas  
Pontificia Universidad Católica de Chile, Primer Semestre 2025

**Resumen**—El monitoreo de condición y la detección temprana de fallas en sistemas dinámicos es fundamental para prevenir fallos catastróficos y optimizar el mantenimiento. Este estudio propone un enfoque basado en el aprendizaje de la dinámica de funcionamiento saludable de un sistema de rodamientos, utilizando exclusivamente datos de operación normal para entrenar modelos predictivos. Se aplicaron tres métodos de extracción de características (FFT, wavelet de Morlet y DeSpaWN), evaluando su desempeño en la reducción del error de predicción y su capacidad para representar adecuadamente la señal vibratoria. Posteriormente, se entrenaron modelos LSTM, Transformer y S4 para modelar la dinámica temporal, destacando el Transformer por su precisión y robustez. Como principal contribución, se implementa una caracterización probabilística de falla mediante la construcción de una zona de peligro, definida a partir de un modelo de regresión logística sobre el error de predicción. Esta zona permite estimar continuamente la probabilidad de falla, superando las limitaciones de los umbrales fijos y ofreciendo una herramienta más sensible, adaptable y realista para la toma de decisiones. Los resultados muestran que el enfoque propuesto es eficaz para detectar el inicio del deterioro del sistema de forma no intrusiva, y se valida su generalización sobre múltiples conjuntos de datos experimentales.

**Index Terms**—LSTM, Transformers, S4, Condition monitoring, Fault detection, Hazard Zone.

## I. INTRODUCCIÓN

ESTA investigación se basa en la construcción de un modelo capaz de aprender la dinámica de funcionamiento de un sistema en condiciones saludables, específicamente en un sistema de rodamientos, con el fin de utilizar dicho conocimiento para monitorear su estado operativo. La idea central es entrenar el modelo exclusivamente con datos de operación normal para luego comparar sus predicciones con datos correspondientes a situaciones de falla, se espera que el error de predicción aumente de forma significativa en comparación con lo observado en condiciones sanas. Esta diferencia permite detectar condiciones anómalas al comparar las predicciones del modelo con los valores reales medidos por sensores.

## II. METODOLOGÍA

### II-A. Descripción del dataset

Los datos utilizados fueron generados por NSF I/UCR Center for Intelligent Maintenance Systems en un ensayo *test to failure*. El ensayo generado para la recopilación de datos consistió en la instalación de cuatro rodamientos Rexnord ZA-2115 en un eje. La velocidad de rotación se mantuvo constante en 2000 RPM mediante un motor de corriente alterna acoplado

al eje. Una carga radial de 6000 libras fue aplicada al eje y a los rodamientos mediante un mecanismo de resorte. Todos los rodamientos fueron constantemente lubricados y se colocaron acelerómetros de cuarzo ICP de alta sensibilidad PCB 353B33 en la carcasa de los rodamientos (dos acelerómetros por rodamiento —en los ejes x e y— para el conjunto de datos 1, y un acelerómetro por rodamiento para los conjuntos de datos 2 y 3). Todas las fallas ocurrieron después de superar la vida útil de diseño del rodamiento, que es superior a 100 millones de revoluciones. En la figura 1 se aprecia mejor lo explicado.




Figura 1. Plataforma de ensayo de rodamientos y representación de la colocación [IMS center (2003)]

En la experimentación se generaron tres sets de datos, que correspondieron a tres distintos *test to failure*. Cada conjunto de datos consiste en archivos individuales que corresponden a capturas de señales de vibración de 1 segundo, registradas a intervalos específicos. Cada archivo contiene 20.480 puntos, con una frecuencia de muestreo de 20 kHz.

Cuadro I  
RESUMEN DE LOS CONJUNTOS DE DATOS DE PRUEBA DE RODAMIENTOS

Set	Nº de archivos	Nº de columnas	Intervalo de grabación	Descripción de falla
1	2156	8	Cada 10 minutos (los primeros 43 archivos cada 5 minutos)	Falla en pista interna del rodamiento 3 y defecto en elemento rodante del rodamiento 4
2	984	4	Cada 10 minutos	Falla en pista externa del rodamiento 1
3	4448	4	Cada 10 minutos	Falla en pista externa del rodamiento 3

Sabiendo que cada archivo posee 20.480 filas entonces tendremos que el set 1 posee 44.154.880 filas, el set 2 tiene 20.152.320 filas y el set 3 tiene 129.515.520 filas.

En el set 1 se tienen las vibraciones en el eje x e y, por lo que se elige utilizar las vibraciones solo del eje y, ya que el set 2 y 3 solo poseen vibraciones en este eje. Borrando así las columnas 1, 3, 5 y 7 del set 1.

## II-B. Manejo de datos

Se realizó un análisis de las frecuencias de vibración características de los cuatro modos de falla en un rodamiento:

- Frecuencia de defecto en pista exterior.
- Frecuencia de defecto en pista interior.
- Frecuencia de defecto en elemento rodante.
- Frecuencia de defecto en jaula.

Se determinó que la frecuencia de muestreo del dataset era excesivamente alta para los fines de detección de fallas a largo plazo, lo que a su vez implicaba una alta carga computacional al procesar series de tiempo tan extensas. Por ello, se optó por reducir la frecuencia de muestreo, asegurándose de ser capaz de identificar todas las frecuencias de vibración de los modos de falla, extrayendo así características cada 256 pasos temporales. Reduciendo así el costo computacional del problema sin perder información.

Para ello, se emplearon tres métodos principales de extracción de características:

- **Fast Fourier Transform (FFT):** Permite descomponer la señal en sus componentes frecuenciales, facilitando la identificación de patrones periódicos asociados a posibles fallas. Este enfoque ha sido validado en numerosos estudios: Zhou et al. (2015) utilizaron la FFT para extraer características de vibración en rodamientos, combinándolas con redes neuronales para una detección precisa de fallas [1]; Majali et al. (2022) confirmaron que la FFT identifica frecuencias fundamentales y armónicas de fallas, logrando alta precisión incluso en etapas incipientes [2].
- **Wavelet de Morlet:** La wavelet es una herramienta de análisis tiempo-frecuencia que generaliza la

transformada de Fourier, permitiendo estudiar señales con componentes transitorias o localizadas. En particular, se emplea para detectar firmas débiles e impulsivas en señales ruidosas, como las generadas por fallas incipientes en rodamientos. La wavelet de Morlet, por su forma similar a un impulso amortiguado, resulta especialmente adecuada para identificar impactos periódicos que suelen estar ocultos por el ruido. Su aplicación en este tipo de señales ha sido documentada por Qiu et al. (2006) en el contexto del diagnóstico de rodamientos [3].

- **DeSpaWN (Deep Sparse Wavelet Network):** Es una red neuronal inspirada en la transformada wavelet discreta, diseñada para aprender automáticamente filtros y umbrales de *denoising* mediante entrenamiento no supervisado. Su arquitectura en cascada permite descomponer la señal en componentes de alta y baja frecuencia a lo largo de múltiples niveles, aplicando umbrales aprendibles para obtener representaciones dispersas y robustas al ruido. Esta arquitectura ha demostrado ser eficaz en la detección de firmas débiles en señales ruidosas, especialmente en entornos industriales de alta frecuencia [4].

En cada uno de los casos, las características extraídas fueron: el promedio de los coeficientes, el valor máximo de los mismos y el error absoluto de reconstrucción, lo que permitió comparar de forma estandarizada el desempeño de cada método. Esta definición de características se basa en el trabajo de Liu et al. (2021) [4] y en un estudio reciente de Brandt et al. (2024) [5], donde se aplica DeSpaWN con ocho niveles de descomposición wavelet, extrayendo explícitamente el promedio y el máximo de los coeficientes FDWT junto al error de reconstrucción, por lo que se mantiene esta filosofía para las tres técnicas analizadas.

Para un posterior entrenamiento de la dinámica del modelo, los datos se pasan por un StandardScaler, para facilitar el aprendizaje del modelo a utilizar, es importante notar que el StandardScaler se utiliza ya que cómo se busca Normalizar señales de vibración. Centrar cada variable en torno a cero y escalarla según su desviación estándar, evitando que alguna característica domine el modelo solo por tener valores mucho más altos.

Finalmente, dado que se busca aprender la dinámica de funcionamiento en condiciones saludables y mantener un equilibrio en los datos de entrenamiento, se define el conjunto de datos sanos como el 40 % inicial del dataset más pequeño, correspondiente al experimento 2 (984 archivos). Este mismo número de muestras (393 archivos) se utiliza también para los experimentos 1 y 3, con el objetivo de equilibrar la cantidad de datos entre los tres casos y reducir la variabilidad en los resultados obtenidos durante el entrenamiento. A partir de estos subconjuntos de datos sanos, se selecciona aleatoriamente un 70 % de los archivos para el entrenamiento

y el 30 % restante se utiliza para validación. Es importante destacar que el modelo se entrena utilizando ventanas temporales extraídas desde cada archivo por separado, por lo que este muestreo aleatorio a nivel de archivo no interfiere con la coherencia temporal de los datos. De esta manera, se preserva la dinámica interna del sistema al mantener intactas las secuencias dentro de cada archivo.

### II-C. Modelado de la dinámica temporal

Para el modelado de la dinámica temporal del sistema, se compara el desempeño de tres arquitecturas: LSTM, Transformer y S4. Cada una implementa una estrategia distinta para capturar dependencias temporales, lo que permite evaluar cuál se ajusta mejor a los datos analizados.

- **LSTM (Long Short-Term Memory):** Introducidas por Hochreiter y Schmidhuber (1997) [6], las LSTM buscan resolver el problema del desvanecimiento del gradiente en redes recurrentes clásicas mediante una arquitectura con compuertas. Estas compuertas —de olvido, entrada y salida— regulan el flujo de información hacia una “memoria” interna, permitiendo retener o descartar información de forma selectiva. Su procesamiento secuencial permite modelar el orden temporal de manera explícita, aunque con limitaciones en paralelización.
- **Transformer:** Propuesto por Vaswani et al. (2017) [7], el Transformer reemplaza la recurrencia por un mecanismo de atención, específicamente el *self-attention*, que permite capturar dependencias entre todos los elementos de una secuencia en paralelo. Esto mejora significativamente la eficiencia en entrenamiento, especialmente en secuencias largas. Además, se incorporan mecanismos de posicionamiento, normalización y conexiones residuales que enriquecen la capacidad de representación.
- **S4 (Structured State Space for Sequences):** El modelo S4, desarrollado por Gu et al. (2022) [8], se basa en modelos de espacio de estados lineales (SSMs) para capturar dependencias temporales. Introduce una parametrización eficiente que permite resolver convoluciones largas mediante transformadas espectrales. A diferencia de LSTM y Transformer, S4 es especialmente eficiente en el modelado de secuencias extensas y con estructura dinámica compleja, utilizando un enfoque numéricamente estable y escalable.

### II-D. Caracterización de fallas

Se espera que el error de predicción de la dinámica del sistema se mantenga dentro de un rango constante mientras el sistema opere en condiciones normales. Sin embargo, este error se debería disparar cuando el sistema se aproxime a una falla.

Para caracterizar la falla se adoptan las siguientes

metodologías:

1. **Umbral de falla:** Se propone utilizar como criterio de detección el instante en el que se alcanza la mayor segunda derivada del error de predicción, lo que indica un cambio abrupto en la dinámica y, por tanto, el inicio de una prealerta de falla.
2. **Zona de peligro:** Siguiendo la filosofía de entrenamiento previamente adoptada, se consideran como datos sanos aquellos correspondientes al inicio del conjunto de datos, y como datos en falla aquellos ubicados al final. No obstante, se introduce una ligera modificación en la partición: dado que es necesario incluir datos de falla que no estaban presentes durante el entrenamiento de la dinámica, se emplea únicamente el dataset 1 para entrenar el clasificador. Se mantiene la misma proporción de datos sanos, mientras que el último 1 % del dataset se considera como datos en falla. Esta estrategia enfatiza la importancia de entrenar adecuadamente la dinámica del sistema, de manera que los resultados sean consistentes y generalizables a otros experimentos bajo condiciones diversas.

Con este enfoque, se busca definir un hiperplano que separe los datos sanos de aquellos con falla. Para ello, se entrena un modelo de regresión logística que genera un hiperplano separador en el espacio del error. A este se le aplica la función sigmoide del regresor logístico para estimar la probabilidad de falla asociada a cada observación.

A partir de esta probabilidad, es posible construir una “zona de peligro” sobre el error de predicción de la dinámica del sistema, evaluando los distintos valores obtenidos. Esto permite representar visualmente la evolución de la probabilidad de falla a medida que el error aumenta al degradarse el sistema.

## III. RESULTADOS

### III-A. Adquisición de características

Para comparar el desempeño de cada método de adquisición de características, se evalúa el entrenamiento de la dinámica del sistema utilizando las características extraídas por cada uno. Para esta comparación se emplea el modelo más simple, la arquitectura LSTM. Además, como aproximación preliminar para la detección de fallas, se define un umbral basado en el comportamiento del error de predicción.

En las figuras 2 a 10 se presentan los resultados del error de predicción medio por archivo para cada uno de los experimentos, según el método de extracción de características utilizado.

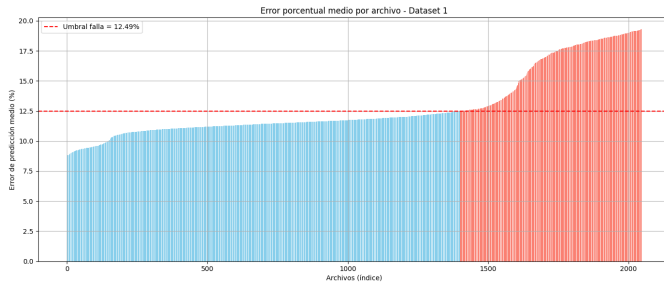


Figura 2. Dinámica al extraer características con FFT Experimento 1 [Elaboración Propia]




Figura 6. Dinámica al extraer características con Wavelet Morlet Experimento 2 [Elaboración Propia]




Figura 3. Dinámica al extraer características con FFT Experimento 2 [Elaboración Propia]




Figura 7. Dinámica al extraer características con Wavelet Morlet Experimento 3 [Elaboración Propia]



Figura 4. Dinámica al extraer características con FFT Experimento 3 [Elaboración Propia]




Figura 8. Dinámica al extraer características con DesPaWN Experimento 1 [Elaboración Propia]




Figura 5. Dinámica al extraer características con Wavelet Morlet Experimento 1 [Elaboración Propia]




Figura 9. Dinámica al extraer características con DesPaWN Experimento 2 [Elaboración Propia]




Figura 10. Dinámica al extraer características con DeSpaWN Experimento 3 [Elaboración Propia]




Figura 12. Dinámica Transformers Experimento 2 [Elaboración Propia]

Cuadro II  
COMPARACIÓN DE MÉTODOS DE PREPROCESAMIENTO

Métrica	FFT	Morlet	DeSpaWN
df1	9,2 %	12,5 %	1,5 %
df2	10,8 %	10,0 %	5,5 %
df3	6,9 %	8,0 %	3,0 %
Media del error	8,97 %	10,17 %	3,33 %
Desviación estándar	1,60 %	1,84 %	1,65 %

En la Tabla II se presentan los valores del error medio obtenidos en los datos sanos de cada experimento para los distintos métodos de extracción de características, junto con el promedio general y su desviación estándar. A partir de estos resultados, se observa que el método DeSpaWN alcanza el menor error medio en todos los experimentos, además de presentar la menor variabilidad entre ellos. Esto sugiere que DeSpaWN es el método más efectivo para representar la dinámica del sistema, ya que generaliza mejor y produce predicciones más precisas.

### III-B. Dinámica del sistema

Con el método de obtención de características definido es posible entrenar cada modelo a partir de los coeficientes extraídos con DeSpaWN, así las dinámicas entrenadas se pueden apreciar en las figuras, para la lstm se mantiene el modelo de las figuras 8 a 10, mientras que para Transformers y S4 se muestra en las figuras 11 a 16.




Figura 11. Dinámica Transformers Experimento 1 [Elaboración Propia]




Figura 13. Dinámica Transformers Experimento 3 [Elaboración Propia]




Figura 14. Dinámica S4 Experimento 1 [Elaboración Propia]




Figura 15. Dinámica S4 Experimento 2 [Elaboración Propia]




Figura 16. Dinámica S4 Experimento 3 [Elaboración Propia]




Figura 17. Zona de peligro experimento 1 [Elaboración Propia]

Cuadro III  
COMPARACIÓN DE MODELOS PARA EL MODELADO DE LA DINÁMICA TEMPORAL

Métrica	LSTM	Transformer	S4
df1	1,5 %	0,15 %	0,01 %
df2	5,5 %	0,12 %	0,055 %
df3	3,0 %	0,12 %	0,075 %
Media del error	3,33 %	0,13 %	0,047 %
Desviación estándar	1,65 %	0,014 %	0,027 %

De acuerdo a la tabla III se observa que tanto el modelo Transformer como el S4 presentan un desempeño superior en comparación con la LSTM. Si bien S4 alcanza el menor error medio, no logra diferenciar de forma efectiva los datos sanos de aquellos con falla en los experimentos 2 y 3, como se aprecia en las figuras 15 y 16. En estos casos, el error de predicción apenas se incrementa, lo que limita su utilidad para los fines de esta investigación. Por otro lado, el modelo Transformer presenta no solo un bajo error medio, sino también la menor desviación estándar entre experimentos, lo que indica una mayor capacidad de generalización y mayor robustez frente a pequeñas variaciones en las condiciones de operación.

III-C. Zona de peligro

Una vez definido el modelo y la arquitectura óptima para capturar la dinámica del sistema, se procede a entrenar un regresor logístico. El resultado para el experimento 1, utilizado durante el entrenamiento, se muestra en la figura 17. En esta, la zona roja representa la probabilidad de que el sistema se encuentre en condición de falla, en función del error de predicción.

Mientras el sistema permanece en estado saludable, el error se mantiene prácticamente constante y la trayectoria se ubica en la zona clara. A medida que se acerca al final de su vida útil, el error de predicción aumenta progresivamente, lo que desplaza la trayectoria hacia la zona más oscura, interpretada como una zona de peligro de falla.

Este comportamiento se extrapola adecuadamente a los experimentos 2 y 3, que no fueron utilizados durante el entrenamiento. Sus resultados se presentan en las figuras 18 y 19, donde se observa un patrón similar manteniéndose en la zona clara en su funcionamiento sano y adentrándose en la transición hacia la zona de riesgo cuando el sistema esté pronto a fallar.




Figura 18. Zona de peligro experimento 2 [Elaboración Propia]




Figura 19. Zona de peligro experimento 3 [Elaboración Propia]

IV. CONCLUSIONES

Fue posible comparar los tres métodos de extracción de características, identificando el más adecuado para este sistema; posteriormente, se evaluaron tres arquitecturas para modelar la dinámica temporal, y finalmente se contrastaron dos enfoques de caracterización de falla, siendo esta última etapa la más relevante de la investigación. Se evidenció que el enfoque basado en una zona de peligro ofrece ventajas significativas frente al uso de un umbral de falla fijo. Esta zona, definida de forma probabilística y estocástica, permite capturar mejor la naturaleza incierta y variable de los sistemas reales. A diferencia del enfoque tradicional de umbrales, esta propuesta resulta más robusta ante el ruido, más representativa del comportamiento real del sistema y además posibilita la implementación de distintos niveles de alerta o respuesta, lo cual es especialmente valioso en aplicaciones de monitoreo de condición.

AGRADECIMIENTOS

Agradecimientos al Profesor David Acuña por su vocación al guiarnos durante el curso y hacer posible este proyecto.

También agradecer a Maximiliano Cruz, ayudante del curso, por compartir sus conocimientos y colaborar con el desarrollo del curso.

#### REFERENCIAS

- [1] Zhou, Y., Zhang, Y., Xu, M., & Liu, Z. (2015). *Fault detection of rolling bearing based on FFT and classification*. ResearchGate. <https://www.researchgate.net/publication/283156328>
- [2] Majali, M., Juremi, N. H., & Mat Darus, I. Z. (2022). *A comparative study of machine learning methods for classification of faults in rotating machinery using FFT-based features*. Journal of Vibroengineering, 24(6), 1123–1137. <https://www.extrica.com/article/22364>
- [3] Qiu, H., Lee, J., Lin, J., & Yu, G. (2006). *Wavelet filter-based weak signature detection method and its application on rolling element bearing prognostics*. Journal of Sound and Vibration, 289(4-5), 1066–1090. <https://doi.org/10.1016/j.jsv.2005.03.007>
- [4] Liu, R., Yang, B., Zio, E., & Chen, X. (2021). *A fully learnable deep wavelet transform for unsupervised monitoring of high-frequency time series*. Proceedings of the National Academy of Sciences, 118(42), e2106598119. <https://doi.org/10.1073/pnas.2106598119>
- [5] Brandt, R., Kumar, S., & Gupta, P. (2024). *Deep Koopman Operator-based degradation modelling using DeSpaWN feature extraction*. Pattern Recognition Letters. <https://doi.org/10.1016/j.patrec.2024.05.003>
- [6] Hochreiter, S., & Schmidhuber, J. (1997). *Long short-term memory*. Neural Computation, 9(8), 1735–1780. <https://doi.org/10.1162/neco.1997.9.8.1735>
- [7] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... & Polosukhin, I. (2017). *Attention is all you need*. Advances in Neural Information Processing Systems, 30. <https://arxiv.org/abs/1706.03762>
- [8] Gu, A., Goel, K., Ré, C. (2022). *Efficiently modeling long sequences with structured state spaces*. International Conference on Learning Representations (ICLR). <https://arxiv.org/abs/2111.00396>