

Efecto de la cantidad de datos CFD y del tamaño de muestra Monte Carlo en la reconstrucción probabilística de la velocidad

Martín Salinas Boloña^a

^aDepartamento de Ingeniería Mecánica y Metalúrgica, Pontificia Universidad Católica de Chile, Santiago, Chile

Resumen

Este trabajo presenta un diseño estadístico computacional aplicado a datos CFD multifásicos con el objetivo de evaluar cómo la cantidad de información CFD disponible y el tamaño de muestra Monte Carlo afectan el error de una reconstrucción probabilística del campo de velocidades. La variable física principal fue la magnitud de velocidad del agua, $|V|$, calculada a partir de las tres componentes de velocidad exportadas desde simulaciones CFD. Se estudiaron dos factores: la duración de la ventana CFD, L_{CFD} , y el número de muestras Monte Carlo, N_{MC} . Se implementó una grilla factorial 3^2 y se ajustó una superficie de respuesta cuadrática sobre $\log_{10}(E)$. Los resultados muestran que N_{MC} es el factor dominante en la reducción del error de reconstrucción, mientras que el efecto de L_{CFD} fue débil dentro del rango estudiado.

Keywords: CFD multifásico; diseño experimental; superficie de respuesta; Monte Carlo; reconstrucción probabilística

1. Introducción

Las simulaciones de dinámica de fluidos computacional, o CFD, permiten estudiar campos de velocidad complejos en sistemas donde la medición experimental directa puede ser difícil, costosa o limitada espacialmente. En flujos multifásicos y turbulentos, esta dificultad aumenta debido a la presencia de estructuras transientes, interacción entre fases y alta demanda computacional. Además, la descripción estadística del flujo suele ser más informativa que una única realización instantánea, especialmente cuando se analizan magnitudes derivadas del vector velocidad.

En este contexto, una pregunta relevante es cuánta información CFD se necesita para obtener una reconstrucción probabilística suficientemente estable del campo de velocidades. Esta pregunta no busca comparar condiciones físicas distintas, sino evaluar la sensibilidad de una metodología de reconstrucción frente a decisiones computacionales. En particular, este estudio analiza dos decisiones: la duración de la ventana temporal CFD utilizada como referencia y el tamaño de muestra Monte Carlo usado para reconstruir la distribución de velocidades.

La variable física de interés es la magnitud de velocidad del agua,

$$|V| = \sqrt{u^2 + v^2 + w^2}, \quad (1)$$

donde u , v y w corresponden a las componentes de velocidad. Esta variable resume la intensidad local del campo de velocidades y es relevante para análisis posteriores asociados al transporte de cantidad de movimiento, mezcla y potencial erosivo del flujo.

Desde el punto de vista estadístico, el problema se abordó mediante diseño de experimentos y metodología de superficie de respuesta (Box and Wilson, 1951; Montgomery, 2013). En este caso, los factores son la duración de ventana CFD, L_{CFD} , y el tamaño de muestra Monte Carlo, N_{MC} . La respuesta principal es el error relativo de la media reconstruida de $|V|$ respecto de la referencia CFD.

La hipótesis del estudio es que, al aumentar tanto la duración de la ventana CFD utilizada como referencia, L_{CFD} , como el número de muestras Monte Carlo, N_{MC} , el error de reconstrucción disminuirá. Sin embargo, se espera que esta reducción no sea necesariamente lineal, sino que pueda presentar rendimientos decrecientes.

2. Metodología

2.1. Datos CFD y unidad experimental

Los datos utilizados provienen de simulaciones CFD independientes de un mismo escenario físico multifásico. Cada simulación se considera una réplica computacional completa bajo las mismas condiciones nominales, por lo que la unidad experimental del estudio es la simulación CFD completa (Montgomery, 2013).

El análisis se restringió al intervalo posterior a $t = 2,0$ s, ya que a partir de este tiempo el flujo se considera desarrollado. A partir de este tiempo se definieron tres ventanas de análisis: 2,0–2,5 s, 2,0–3,0 s y 2,0–3,5 s, equivalentes a duraciones $L_{CFD} = 0,5, 1,0$ y $1,5$ s. Para cada ventana se utilizaron dos réplicas CFD independientes.

Cuadro 1: Datos de simulaciones CFD utilizadas en el estudio.

Caso	t_{fin} [s]	Réplica	Archivos	Puntos totales	t_{min} [s]	t_{max} [s]	Tamaño [MB]
T2p5_R1	2.5	1	249	3 300 993	2.002	2.498	372.58
T2p5_R2	2.5	2	231	3 062 367	2.002	2.462	345.49
T3p0_R1	3.0	1	500	6 628 500	2.002	3.000	749.50
T3p0_R2	3.0	2	500	6 628 500	2.002	3.000	749.12
T3p5_R1	3.5	1	750	9 942 750	2.002	3.500	878.03
T3p5_R2	3.5	2	750	9 942 750	2.002	3.500	1122.32

2.2. Análisis exploratorio de datos y preprocesamiento

Antes del diseño experimental se realizó un análisis exploratorio de los datos CFD con tres objetivos: verificar la disponibilidad de archivos, definir una base de datos consistente para la reconstrucción Monte Carlo y detectar regiones que pudieran distorsionar la distribución global de $|V|$.

El inventario de datos mostró dos aspectos relevantes. Primero, la ventana corta presenta una pérdida parcial de archivos: T2p5_R1 contiene 249 archivos y T2p5_R2 contiene 231, en lugar de los 250 esperados. Segundo, aunque T3p5_R1 y T3p5_R2 tienen el mismo número de archivos, sus tamaños de carpeta son distintos, lo que sugiere una posible diferencia en exportación o de resolución. Estas observaciones no impiden el análisis, pero se consideran limitaciones del estudio y justifican comparar cada reconstrucción Monte Carlo contra su propia referencia CFD local.

El análisis inicial de $|V|$ mostró una subpoblación marcada de valores altos cercana a $|V| \approx 2,5$, asociada a una condición de borde de la simulación. Esta región corresponde a una capa límite espacialmente muy pequeña dentro del dominio, por lo que su peso en la distribución global no representa proporcionalmente el volumen de flujo de interés para la reconstrucción probabilística. Para evitar que esta región localizada controlara la reconstrucción probabilística, se aplicó el criterio de filtrado

$$|V| < 2,45. \quad (2)$$

El umbral se contrastó con el criterio extremo de Tukey,

$$Q_3 + 3IQR, \quad (3)$$

y en todos los casos quedó por encima del límite extremo (Tukey, 1977). Además, el porcentaje de puntos eliminados fue 6.517% en cada simulación, lo que indica que no corresponde a ruido aislado, sino a una subpoblación sistemática. La Figura 1 muestra visualmente el efecto del filtrado, mientras que la Tabla 2 resume su impacto sobre la media y desviación estándar de $|V|$.

Cuadro 2: Efecto del filtrado $|V| < 2,45$ sobre la distribución global de $|V|$.

Caso	% eliminado	Media inicial	Media filtrada	Desv. est. inicial	Desv. est. filtrada
T2p5_R1	6.517	0.704	0.579	0.551	0.291
T2p5_R2	6.517	0.708	0.584	0.550	0.291
T3p0_R1	6.517	0.692	0.566	0.555	0.293
T3p0_R2	6.517	0.719	0.595	0.552	0.300
T3p5_R1	6.517	0.713	0.588	0.556	0.306
T3p5_R2	6.517	0.751	0.629	0.546	0.303

El filtrado redujo la media de $|V|$ entre 16.2% y 18.2%, y redujo aproximadamente a la mitad la desviación estándar. Esto confirma que la subpoblación cercana a la condición de borde tenía un peso importante en los estadísticos globales. Por esta razón, el análisis principal se realizó con la base filtrada.

Después del filtrado, la distribución de $|V|$ siguió sin ser normal. Esto fue verificado mediante Shapiro-Wilk sobre submuestras aleatorias de 5000 valores por caso CFD, obteniéndose valores p extremadamente bajos en todos los casos (Shapiro and Wilk, 1965). Los QQ plots, boxplots y la distribución espacial de $|V|$ se presentan en el Anexo A, donde se documenta con mayor detalle la no normalidad, la presencia de valores extremos y la localización espacial de la subpoblación filtrada.




Figura 1: Distribución de la magnitud de velocidad $|V|$ antes y después del filtrado con $|V| < 2,45$. A la izquierda se observa la subpoblación de valores altos asociada a la condición de borde, a la derecha se muestra la distribución usada para el análisis principal.

2.3. Diseño experimental computacional

El diseño experimental computacional consideró dos factores controlables: la duración de la ventana CFD utilizada como referencia, L_{CFD} , y el tamaño de muestra Monte Carlo, N_{MC} . Los niveles de L_{CFD} fueron 0.5, 1.0 y 1.5 s, mientras que los niveles de N_{MC} fueron 250, 1000 y 4000. Estos niveles definen una grilla factorial 3^2 .

Este tipo de diseño permite estudiar simultáneamente los efectos principales de ambos factores, una posible interacción entre ellos y la presencia de curvatura en la respuesta.

Las variables codificadas se definieron como

$$x_L = \frac{L_{CFD} - 1,0}{0,5}, \quad (4)$$

y

$$x_N = \frac{\log_{10}(N_{MC}) - \log_{10}(1000)}{\log_{10}(4)}. \quad (5)$$

El uso de variables codificadas permite expresar los factores en una escala común y facilita la comparación de los coeficientes del modelo empírico, ya que estos quedan adimensionales y representan cambios sobre intervalos equivalentes de los factores. En el caso de N_{MC} , la codificación se realizó en escala logarítmica porque los niveles elegidos son multiplicativos: 250, 1000 y 4000 difieren por un factor cuatro entre niveles consecutivos. Por ello, la transformación logarítmica permite representar estos niveles de forma simétrica en la escala codificada.




Figura 2: Matriz del diseño experimental en coordenadas codificadas (x_N, x_L) . Los nueve puntos corresponden a todas las combinaciones de los tres niveles de L_{CFD} y N_{MC} , formando una grilla factorial 3^2 .

2.4. Reconstrucción Monte Carlo y referencia CFD específica

El procedimiento Monte Carlo se utilizó para evaluar cuántas muestras son necesarias para reconstruir de forma estable los estadísticos de la distribución de $|V|$ (Kroese et al., 2011). Para cada simulación CFD, se tomó como referencia la distribución empírica completa de $|V|$ obtenida desde la base filtrada. Luego, se generaron muestras Monte Carlo de tamaño N_{MC} y se comparó la media reconstruida con la media de la referencia CFD correspondiente.

En este contexto, la reconstrucción Monte Carlo no busca generar una nueva simulación ni recuperar el vector instantáneo de velocidad en cada punto del dominio. Su objetivo es estimar observables estadísticos de la distribución de velocidades, tales como la media de $|V|$, usando solo una cantidad limitada de muestras. Por lo tanto, el error mide la diferencia entre una estimación Monte Carlo basada en N_{MC} muestras y la referencia empírica calculada con todos los datos CFD disponibles para esa misma condición.

Cada reconstrucción Monte Carlo se comparó con su referencia CFD específica. Es decir, una muestra generada desde T2p5_R1 se comparó con la distribución completa filtrada de T2p5_R1, y no con otra réplica ni con otra ventana temporal. Esta decisión evita mezclar el error propio del procedimiento Monte Carlo con diferencias naturales entre simulaciones CFD independientes.

La respuesta principal del diseño fue el error relativo de la media de $|V|$,

$$E_{rel} = \frac{|\bar{V}_{MC} - \bar{V}_{CFD}|}{\bar{V}_{CFD}}. \quad (6)$$

donde $\bar{V}_{MC}$ corresponde a la media de $|V|$ estimada a partir de la muestra Monte Carlo y $\bar{V}_{CFD}$ corresponde a la media de $|V|$ de la referencia CFD completa filtrada para la misma simulación y ventana temporal.

2.5. Análisis estadístico

El análisis estadístico se realizó mediante un modelo de superficie de respuesta. Dado que el diseño experimental considera dos factores codificados, x_L y x_N , con tres niveles cada uno, es posible ajustar un modelo cuadrático que incluya efectos lineales, curvatura e interacción. El modelo se ajustó sobre la transformación logarítmica de la respuesta,

$$\log_{10}(E) = \beta_0 + \beta_1 x_L + \beta_2 x_N + \beta_{11} x_L^2 + \beta_{22} x_N^2 + \beta_{12} x_L x_N. \quad (7)$$

La transformación $\log_{10}(E)$ se utilizó porque el error es una respuesta positiva, asimétrica y con cambios aproximadamente multiplicativos respecto de N_{MC} . Esta elección es consistente con el uso de transformaciones de respuesta para variables sesgadas o no normales (Montgomery, 2013).

El ajuste se realizó mediante mínimos cuadrados ordinarios sobre los errores agregados por combinación de factores y réplica CFD. Esta agregación evita tratar las repeticiones Monte Carlo como réplicas experimentales independientes. La significancia de los términos se evaluó mediante sus coeficientes, errores estándar, estadísticos t y valores p , complementados con un análisis ANOVA del modelo.

La adecuación del modelo se evaluó mediante el coeficiente de determinación, el coeficiente de determinación ajustado, residuos versus valores ajustados y QQ plot de residuos. El gráfico de residuos versus ajustados permite revisar si queda una estructura sistemática no capturada por el modelo, mientras que el QQ plot permite evaluar si los residuos del modelo transformado son razonablemente compatibles con normalidad.

3. Resultados y discusión

3.1. Efecto del tamaño de muestra Monte Carlo y de la duración de ventana CFD

El resultado más claro del diseño fue la reducción del error al aumentar N_{MC} . Para $N_{MC} = 250$, el error relativo medio de $|V|$ fue cercano a 0.025. Para $N_{MC} = 1000$, bajó a aproximadamente 0.013. Para $N_{MC} = 4000$, se redujo a valores cercanos a 0.006. Esta tendencia fue consistente para las tres ventanas CFD.

Cuadro 3: Resultados agregados del diseño para el error relativo de la media de $|V|$.

L_{CFD} [s]	N_{MC}	Réplicas CFD	E_{rel} medio	Desv. est.
0.5	250	2	0.025801	0.001334
0.5	1000	2	0.012784	0.000382
0.5	4000	2	0.006055	0.000161
1.0	250	2	0.025391	0.002714
1.0	1000	2	0.013278	0.000319
1.0	4000	2	0.005792	0.000507
1.5	250	2	0.024451	0.000315
1.5	1000	2	0.012608	0.002114
1.5	4000	2	0.005796	0.000455

La disminución del error con N_{MC} es coherente con el comportamiento esperado de una aproximación Monte Carlo. Al aumentar el tamaño de muestra, la estimación de la media reconstruida se vuelve más estable y se

acerca a la referencia empírica local. En cambio, el efecto de L_{CFD} fue menos evidente. A igual tamaño Monte Carlo, las diferencias de error entre ventanas fueron pequeñas. Por ejemplo, para $N_{MC} = 4000$, los errores medios fueron 0.006055, 0.005792 y 0.005796 para $L_{CFD} = 0,5$, 1.0 y 1.5 s, respectivamente.

Estos resultados sugieren que, dentro del rango estudiado, extender la ventana CFD no produjo una reducción clara del error. Sin embargo, esto no implica que L_{CFD} sea irrelevante en general, sino que su efecto fue menor que el de N_{MC} bajo las condiciones evaluadas.

3.2. Modelo de superficie de respuesta

El modelo cuadrático ajustado sobre $\log_{10}(E)$ presentó un buen ajuste global, con $R^2 = 0,990$ y $R^2_{ajustado} = 0,986$. Esto indica que la superficie de respuesta explica gran parte de la variabilidad observada en el error agregado.

Cuadro 4: Resumen del ajuste del modelo cuadrático de superficie de respuesta.

Observaciones	R^2	$R^2_{ajustado}$	AIC	BIC
18	0.990252	0.986190	-68.804581	-63.462350

Los coeficientes del modelo muestran que el único efecto claramente significativo fue x_N , con un coeficiente negativo de -0.316 y un valor p de $1,98 \times 10^{-13}$. Esto confirma que aumentar N_{MC} reduce significativamente el error. En cambio, x_L , los términos cuadráticos y la interacción no fueron estadísticamente significativos dentro del diseño evaluado.

Cuadro 5: Coeficientes del modelo cuadrático ajustado sobre $\log_{10}(E)$.

Término	Coeficiente	Error est.	t	Valor p
Intercepto	-1.887722	0.016552	-114.048	$1,38 \times 10^{-19}$
x_L	-0.008610	0.009066	-0.950	0.361
x_N	-0.316089	0.009066	-34.866	$1,98 \times 10^{-13}$
x_L^2	-0.004797	0.015703	-0.305	0.765
x_N^2	-0.024149	0.015703	-1.538	0.150
$x_L x_N$	0.000862	0.011103	0.078	0.939

El análisis ANOVA entrega la misma interpretación (Montgomery, 2013). El factor x_N tuvo un estadístico $F = 1215,61$ y un valor $p = 1,98 \times 10^{-13}$, mientras que los demás términos no fueron significativos. Por lo tanto, el tamaño Monte Carlo domina la respuesta del diseño.




Figura 3: Diagnóstico del modelo cuadrático ajustado sobre $\log_{10}(E)$: residuos versus valores ajustados y QQ plot de residuos.

La Figura 3 muestra que los residuos no presentan una estructura sistemática clara respecto de los valores ajustados, lo que sugiere que el modelo cuadrático captura adecuadamente la tendencia principal de la respuesta. El QQ plot de residuos muestra una alineación razonable con la referencia normal, con posibles desviaciones

menores en las colas. Por lo tanto, la transformación logarítmica resulta adecuada para estabilizar la respuesta y sostener la interpretación del modelo.




Figura 4: Superficie de respuesta del error relativo predicho. El contorno y la visualización 3D muestran que la reducción del error está dominada por el aumento de N_{MC} .

La superficie de respuesta predice el menor error dentro del dominio evaluado en $L_{CFD} = 1,5$ s y $N_{MC} = 4000$, con un error relativo predicho de aproximadamente 0.00575. Sin embargo, dado que el efecto de L_{CFD} no fue estadísticamente significativo, esta condición debe interpretarse principalmente como consecuencia del mayor N_{MC} , no como evidencia fuerte de que la ventana más larga sea necesariamente óptima.

3.3. Evaluación de la hipótesis y limitaciones

La hipótesis del estudio se verifica parcialmente. El error disminuyó claramente al aumentar N_{MC} , lo que confirma que el tamaño de muestra Monte Carlo es el factor dominante en la calidad de la reconstrucción. En cambio, no se observó una reducción significativa del error asociada a L_{CFD} dentro del rango evaluado. Por lo tanto, la evidencia apoya la parte de la hipótesis asociada al tamaño Monte Carlo, pero no permite sostener con fuerza que extender la ventana CFD entre 0.5 y 1.5 s reduzca el error de reconstrucción.

Las principales limitaciones del estudio son la baja cantidad de réplicas CFD por ventana, la pérdida parcial de archivos en la ventana corta y la posible diferencia de tamaño o resolución entre algunas réplicas largas. En particular, los casos T2p5_R1 y T2p5_R2 presentan menos archivos que lo esperado, mientras que T3p5_R1 tiene un tamaño de carpeta menor que T3p5_R2 pese a tener el mismo número de archivos. Estas diferencias no invalidan el análisis, pero deben considerarse al interpretar comparaciones entre réplicas.

Otra limitación es que la malla CFD no representa una muestra espacial uniforme del dominio. Por ello, las distribuciones empíricas de $|V|$ reflejan tanto la física del flujo como la densidad de puntos exportados. Además, las repeticiones Monte Carlo estabilizan la estimación del error, pero no aumentan el número de réplicas experimentales independientes.

4. Conclusiones

Este estudio implementó un diseño estadístico computacional para evaluar cómo la duración de la ventana CFD y el tamaño de muestra Monte Carlo afectan el error de una reconstrucción probabilística de campos de velocidad multifásicos. La variable principal fue la magnitud de velocidad del agua, $|V|$, reconstruida a partir de datos CFD filtrados.

El análisis exploratorio permitió identificar una subpoblación extrema asociada a una condición de borde, que fue excluida mediante el criterio $|V| < 2,45$. También se verificó que la distribución de $|V|$ no es normal, incluso después del filtrado. Estos resultados justifican el uso de métricas distribucionales y de una transformación logarítmica para modelar el error de reconstrucción.

El diseño factorial 3^2 y el modelo cuadrático de superficie de respuesta mostraron que el factor dominante es N_{MC} . Al aumentar el tamaño de muestra Monte Carlo de 250 a 4000, el error relativo medio de $|V|$ disminuyó desde valores cercanos a 0.025 hasta valores cercanos a 0.006. En cambio, el efecto de L_{CFD} fue menor y no significativo dentro del rango estudiado.

En consecuencia, para este caso CFD multifásico, la mejora más clara en la reconstrucción probabilística proviene de aumentar el tamaño de muestra Monte Carlo. Extender la ventana CFD puede aportar información adicional, pero su efecto fue limitado en comparación con N_{MC} . Futuros trabajos deberían incorporar más réplicas CFD independientes y considerar ponderación volumétrica si se busca representar el dominio físico completo de manera espacialmente uniforme.

Declaración de uso de IA

El uso de herramientas de inteligencia artificial en este trabajo se declara en el documento suplementario `declaracion_ia.pdf`, entregado junto con este informe.

5. Anexos

A. Análisis exploratorio suplementario

Esta sección presenta diagnósticos complementarios usados para respaldar el filtrado de datos, la no normalidad de $|V|$ y el carácter localizado de la subpoblación asociada a la condición de borde.

Cuadro 6: Diagnóstico de normalidad de $|V|$ filtrado usando Shapiro-Wilk sobre submuestras aleatorias de 5000 valores por caso CFD ([Shapiro and Wilk, 1965](#)).

Caso	Asimetría	Curtosis	Shapiro W	Valor p
T2p5_R1	1.508947	2.178231	0.865324	$2,37 \times 10^{-54}$
T2p5_R2	1.475687	2.059709	0.869863	$9,56 \times 10^{-54}$
T3p0_R1	1.541498	2.201580	0.844648	$6,53 \times 10^{-57}$
T3p0_R2	1.373330	1.682431	0.877566	$1,12 \times 10^{-52}$
T3p5_R1	1.370534	1.587647	0.876089	$6,92 \times 10^{-53}$
T3p5_R2	1.243893	1.305201	0.896491	$8,59 \times 10^{-50}$

La Tabla 6 confirma que $|V|$ no sigue una distribución normal aun después del filtrado.




Figura 5: Boxplots de $|V|$ por caso CFD. Los valores altos sistemáticos respaldan el uso de un filtrado robusto para excluir la subpoblación asociada a la condición de borde.




Figura 6: QQ plots de $|V|$ filtrado por caso CFD. La curvatura respecto de la línea de referencia evidencia desviaciones respecto de la normalidad (Montgomery and Runger, 2011).




Figura 7: Distribución espacial de $|V|$. Los valores altos se concentran en una región localizada, compatible con una capa límite asociada a la condición de borde.

B. Métricas suplementarias de Monte Carlo y diseño

Esta sección incluye gráficos complementarios del diseño Monte Carlo. Ambos respaldan que la reducción del error está dominada por el aumento de N_{MC} .




Figura 8: Convergencia del error relativo de la media de $|V|$ al aumentar N_{MC} .




Figura 9: Mapa de calor del error relativo de la media de $|V|$ en función de L_{CFD} y N_{MC} .

Referencias

- Box, G. E. P., & Wilson, K. B. (1951). On the experimental attainment of optimum conditions. *Journal of the Royal Statistical Society: Series B*, 13(1), 1–45. <https://doi.org/10.1111/j.2517-6161.1951.tb00067.x>
- Kroese, D. P., Taimre, T., & Botev, Z. I. (2011). *Handbook of Monte Carlo Methods*. John Wiley & Sons. <https://doi.org/10.1002/9781118014967>
- Montgomery, D. C. (2013). *Design and Analysis of Experiments* (8th ed.). John Wiley & Sons. <https://www.wiley.com/en-us/Design+and+Analysis+of+Experiments>
- Montgomery, D. C., & Runger, G. C. (2011). *Applied Statistics and Probability for Engineers* (5th ed.). John Wiley & Sons. <https://www.wiley.com/en-us/Applied+Statistics+and+Probability+for+Engineers>
- Shapiro, S. S., & Wilk, M. B. (1965). An analysis of variance test for normality (complete samples). *Biometrika*, 52(3–4), 591–611. <https://doi.org/10.1093/biomet/52.3-4.591>
- Tukey, J. W. (1977). *Exploratory Data Analysis*. Addison-Wesley.